

Projeto Final: Aplicação de Machine Learning Clássico

Brazilian E-Commerce Public Dataset by Olist:

Autores: Guilherme Rosa e Miguel Machado.

1. INTRODUÇÃO, PROBLEMA E JUSTIFICATIVA

1.1. CONTEXTUALIZAÇÃO DO PROBLEMA REAL:

- 1.1.1. **Domínio de Aplicação:** E-commerce e Logística preditiva.
- 1.1.2. **Situação Atual:** O comércio eletrônico brasileiro enfrenta desafios logísticos complexos devido à vastidão territorial e à infraestrutura variável. Atrasos nas entregas são um dos principais fatores de insatisfação do consumidor, gerando avaliações negativas, altos custos de atendimento ao cliente (SAC) e perda direta de recompra (churn logístico). Atualmente, a maioria das empresas atua de forma reativa, liderando com o problema apenas após o cliente registrar a reclamação.
- 1.1.3. **Base Teórica:** Portais como o Reclame Aqui podem ser utilizados como fontes de contextualização do problema logístico, pois reúnem reclamações que descrevem falhas operacionais, como atrasos nas entregas, rastreamento impreciso e problemas em tentativas de entrega. Outra fonte de contextualização é o Portal E-Commerce Brasil, que discute o problema sob uma perspectiva mais ampla da economia e da logística. Reportagens e análises do setor destacam desafios como custos de frete, gargalos sazonais e limitações de infraestrutura.

1.2. DEFINIÇÃO DO PROBLEMA DE MACHINE LEARNING:

- 1.2.1. **Definição Técnica:** O problema será tratado em duas etapas. A primeira consiste em uma classificação binária, utilizando o Random Forest Classifier, para prever o risco de atraso de um pedido. A segunda consiste em um problema de regressão, utilizando Regressão Linear Múltipla e Regressão Polinomial,

para estimar a quantidade de dias de atraso dos pedidos identificados como em risco.

1.2.2. **Variável Alvo (Target):**

1.2.3. Alvo 1 (Classificação): Risco binário de atraso: 1 para atrasado e 0 para pedido entregue no prazo ou antes do prazo.

1.2.4. Alvo 2 (Regressão): Dias de atraso: variável contínua que representa a quantidade de dias excedentes em relação à data estimada de entrega.

1.2.5. **Dataset Escolhido:**

1.2.6. Order Dataset: esse é o dataset principal. Através dele encontramos todas as informações.

https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce?select=olist_orders_dataset.csv

Order Items Dataset: esse dataset inclui dados sobre os itens comprados.

https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce?select=olist_order_items_dataset.csv

1.3. JUSTIFICATIVA E RELEVÂNCIA (O Porquê) (O que deve conter):

1.3.1. **Impacto:** A solução proposta busca melhorar o entendimento e a antecipação de possíveis atrasos na entrega dos produtos, fornecendo uma estimativa de risco e uma estimativa da quantidade de dias de atraso.

1.2.2. **Relevância:** O uso de Machine Learning é relevante para este problema porque permite analisar ao mesmo tempo diversas características dos pedidos e identificar padrões associados aos atrasos. Dessa maneira, a abordagem pode completar análises tradicionais e oferecer uma estratégia preditiva para apoiar decisões logísticas..

1.3. OBJETIVOS

1.3.1. OBJETIVO GERAL:

1.2.1.1. Desenvolver e comparar modelos de Machine Learning para prever o risco de atraso no envio de produtos e estimar a quantidade de dias perdidos, otimizando a operação logística no contexto do e-commerce brasileiro utilizando a base de dados pública da Olist.

1.3.2. OBJETIVOS ESPECÍFICOS (O que deve conter):

1.3.2.1. Lista de passos técnicos e sequenciais:

- a) Obter, inspecionar e estruturar os datasets utilizados, verificando tipos de dados, chaves de relacionamento e consistência das informações.
- b) Realizar a Análise Exploratória de Dados (EDA) para diagnosticar nulos, validar o formato das datas, identificar possíveis outliers e visualizar a distribuição dos atrasos nas entregas.
- c) Implementar o pipeline de pré-processamento e Engenharia de Atributos, convertendo strings para datetime e agregando informações dos itens por pedido e criando a variável calculada *dias_atraso*.
- d) Treinar e otimizar um modelo de Random Forest para classificação do risco de atraso e modelos de Regressão Linear Múltipla e Regressão Polinomial para estimar a quantidade de dias de atraso.
- e) Integrar as etapas de classificação e regressão, utilizando a informação de risco produzida pelo classificador como parte das variáveis da etapa de estimativa de dias de atraso.
- f) Avaliar o desempenho dos modelos utilizando métricas adequadas ao problema, incluindo Accuracy, Precision, Recall, F1-Score e ROC-AUC para classificação e MAE, RMSE e R^2 para regressão.

1.4. FUNDAMENTAÇÃO TEÓRICA

1.4.2.1. REVISÃO BIBLIOGRÁFICA DO DOMÍNIO

- a) **CONCEITOS CHAVE DO DOMÍNIO:** O foco do problema incide sobre o SLA Logístico (Service Level Agreement), relacionado ao prazo prometido de entrega entre a loja e o cliente. A quebra desse prazo pode aumentar a insatisfação do consumidor, especialmente na etapa de Last Mile Delivery, correspondente à fase final da entrega.

b) SOLUÇÕES NÃO-ML EXISTENTES: Sem algoritmos preditivos, uma estratégia é trabalhar com margem adicional de prazo na estimativa de entrega, buscando parte dos imprevistos logísticos. O problema dessa abordagem é que prazos artificialmente longos podem reduzir a atratividade da oferta no momento da compra. A proposta deste trabalho é investigar uma abordagem preditiva que considere características observadas dos pedidos para estimar o risco e a intensidade do atraso.

1.3.3.2. REFERENCIAL TEÓRICO EM MACHINE LEARNING


- a) **MODELO DE CLASSIFICAÇÃO - Random Forest:** O Random Forest Classifier é um modelo de ensemble baseado na combinação de diversas árvores de decisão. As árvores são treinadas utilizando diferentes amostras dos dados e subconjuntos de variáveis, e a decisão final é obtida pela combinação das previsões produzidas pelo conjunto. Neste projeto, o modelo será utilizado para classificar os pedidos em duas classes: sem atraso e com atraso. Além da classe prevista, o modelo também poderá fornecer uma probabilidade estimada para a classe de atraso, informação que será utilizada na etapa seguinte do pipeline.
- b) **MODELO DE REGRESSÃO (Regressão Linear Múltipla):** A Regressão Linear Múltipla é um algoritmo de regressão que busca estabelecer uma relação matemática entre múltiplas variáveis independentes e uma variável contínua de saída. Neste projeto, será utilizada para estimar a quantidade de dias de atraso a partir das características disponíveis no pedido e da informação de risco produzida na etapa de classificação.
- c) **REGRESSÃO POLINOMIAL:** A Regressão Polinomial será utilizada como uma extensão da abordagem linear. Por


meio da criação de características polinomiais e de interações entre as variáveis, será possível representar relações não lineares entre os atributos de entrada e a quantidade de dias de atraso. O desempenho dessa abordagem será comparado com o da Regressão Linear Múltipla.

1.5. METODOLOGIA E DESENVOLVIMENTO

1.5.1. ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

- a) **Descrição Detalhada:** A base original contém registros de pedidos e itens de compras. Após o cruzamento pela chave `order_id`, os dados serão organizados 5 no nível do pedido, permitindo combinar características logísticas com informações agregadas dos itens, como quantidade de itens, valor total e frete.
- b) **Diagnóstico dos Dados:** O diagnóstico da EDA deverá verificar pedidos com datas nulas, principalmente em campos relacionados à entrega, além de identificar valores extremos que possam distorcer a análise. Também serão verificadas as distribuições das variáveis numéricas e a proporção de pedidos atrasados e não atrasados.
- c) **Visualizações:**





1.5.2. PRÉ-PROCESSAMENTO E FEATURE ENGINEERING

- a) **Divisão de Dados:** Os dados serão separados na proporção de 70% para Treinamento e 30% para Teste. O conjunto de teste permanecerá separado durante o treinamento para permitir uma avaliação final com dados não utilizados no ajuste dos modelos.
- b) **Tratamento de Nulos:** Serão removidos ou tratados os registros que não possuam as informações essenciais para a definição do alvo e das variáveis utilizadas no treinamento. Pedidos sem data efetiva de entrega não serão utilizados para calcular o atraso observado.
- c) **Codificação Categórica:** Nesta primeira versão do pipeline, as variáveis utilizadas diretamente nos modelos serão predominantemente numéricas. Caso variáveis categóricas adicionais sejam incorporadas ao modelo, será utilizado One-Hot Encoding por meio do pipeline de pré-processamento.
- d) **Escalação/Normalização:** O Random Forest não depende de padronização das variáveis para realizar as divisões das árvores. Nas etapas de regressão, a necessidade de escalonamento será tratada dentro do pipeline do modelo para manter o pré-processamento separado dos dados de teste.

- e) **Engenharia de Atributos:** O pacote pandas será utilizado para conversão de datas e cálculo de diferenças entre timestamps. Serão criadas variáveis derivadas, como tempo de aprovação, prazo estimado de entrega, prazo para envio, relação entre frete e valor do pedido e componentes de calendário da compra. A variável dias_atraso será calculada a partir da diferença entre a data efetiva de entrega e a data estimada. Os dias atrasados, convertendo lógica de relógio em números absolutos interpretáveis pela máquina.

1.5.3. IMPLEMENTAÇÃO, TREINAMENTO E OTIMIZAÇÃO DOS MODELOS

- a) **Detalhes de Implementação:** A implementação será realizada em Python utilizando principalmente pandas para manipulação dos dados, matplotlib para visualização e scikit-learn para pré-processamento, treinamento, otimização e avaliação dos modelos. O Random Forest será responsável pela classificação do risco, enquanto a Regressão Linear Múltipla e a Regressão Polinomial serão utilizadas na estimativa dos dias de atraso.
- b) **Integração entre os modelos:** Após o treinamento do Random Forest, a probabilidade estimada de atraso será utilizada como uma variável adicional na etapa de regressão. Dessa forma, a classificação fornece uma informação de risco que complementa as demais características do pedido na estimativa da quantidade de dias de atraso.
- c) **Otimização:** Os hiperparâmetros do Random Forest e das transformações utilizadas na regressão serão ajustados por técnicas de busca de parâmetros, como GridSearchCV ou RandomizedSearchCV, utilizando apenas o conjunto de treinamento.

1.5.4. AVALIAÇÃO E ANÁLISE DE RESULTADOS (O que deve conter):

- a) **Comparação Quantitativa - Classificação:** O desempenho do Random Forest no conjunto de teste será apresentado por meio de Accuracy, Precision, Recall, F1-Score e ROC-AUC. Como o problema envolve identificar pedidos que realmente sofrerão atraso, o Recall será analisado com atenção, pois falsos negativos representam pedidos atrasados que não foram identificados como de risco.
- b) **Justificativa das Métricas:** As métricas serão interpretadas em conjunto. A Accuracy mostra a proporção geral de classificações corretas; a Precision indica a proporção de pedidos classificados como atrasados que realmente apresentaram atraso; o Recall indica a capacidade de encontrar pedidos que efetivamente atrasaram; e o F1-Score resume o equilíbrio entre Precision e Recall. A ROC-AUC será utilizada como medida adicional da capacidade de discriminação do classificador.
- c) **Visualizações:** Serão incluídos gráficos de avaliação, como Matriz de Confusão e Curva ROC, além das visualizações da EDA. Também será analisada a importância das variáveis no Random Forest, quando aplicável.
- d) **Análise da Regressão:** Na etapa de regressão, a avaliação será realizada por métricas de erro e de ajuste. O MAE (Mean Absolute Error) será utilizado para indicar, em dias, o tamanho médio absoluto do erro. O RMSE (Root Mean Squared Error) dará maior peso aos erros mais elevados, enquanto o R^2 indicará a proporção da variação do alvo explicada pelo modelo no conjunto avaliado.
- e) **Integração do Pipeline:** Além da avaliação isolada dos modelos, será analisado o comportamento da sequência completa, desde a classificação do risco até a estimativa

do número de dias de atraso. Os resultados numéricos e gráficos serão preenchidos após a execução do pipeline sobre os datasets brutos.

1.5.5. CONCLUSÃO, PRODUTO FINAL E CRONOGRAMA

1.5.5.1. ENTREGÁVEIS OBRIGATÓRIOS:

- a) Código-fonte:** <https://github.com/Guiborgesilva/olist-ml>
- b) Apresentação:** Slides para a defesa oral do projeto.